

Mini Proyecto: Sistema de Sentiment Analysis con NLP

Resultados reales con Amazon Reviews: Kindle Store Category

Pablo García Espejo
Diego Arath Franco Herrera
Miguel Ángel Guerrero Álvarez
Manuel de la Torre
Giulian Thibaut Elías-Libera

Materia: Minería de Datos y Ciencia de Datos
Profesor: M.C. Eduardo Francisco Sánchez Ocampo

19 de febrero de 2026

Agenda

1. Objetivo y problema de clasificación.
2. Dataset utilizado y preparación de etiquetas.
3. Pipeline NLP implementado.
4. Modelos y experimentos.
5. Evidencia de ejecución real.
6. Resultados, matrices de confusión y mejor configuración.
7. Conclusiones y participación del equipo.

Objetivo del proyecto

Construir un sistema completo de *Sentiment Analysis* con técnicas de *Natural Language Processing* para clasificar reseñas de Amazon Kindle como **positivas** o **negativas**.

Entrada

- Reseñas escritas por usuarios.
- Calificación numérica original.
- Dataset de Amazon Kindle.

Salida

- Etiqueta positiva: 1.
- Etiqueta negativa: 0.
- Métricas de clasificación.

Dataset utilizado

Fuente

- *Amazon Reviews: Kindle Store Category.*
- Fuente: Kaggle.
- Archivo usado:
`data/raw/kindle_reviews.csv`.

Clase	Cantidad
Positivo	829,256
Negativo	57,148
Total	886,404

Punto clave

El dataset está desbalanceado: la clase positiva domina. Por eso se revisa **F1-score** además de accuracy.

Conversión de calificaciones a sentimiento

Calificación original	Tratamiento	Etiqueta final
4 o 5	Reseña positiva	1
1 o 2	Reseña negativa	0
3	Se elimina por neutralidad	No aplica

La calificación 3 se elimina porque representa una opinión neutral y puede introducir ambigüedad en un problema binario.

Pipeline implementado



El flujo cubre desde el texto crudo hasta la comparación final de modelos y evidencias de ejecución.

Preprocesamiento NLP

Limpieza de texto

- Minúsculas.
- Eliminación de URLs.
- Eliminación de HTML.
- Eliminación de puntuación.
- Eliminación de números y caracteres especiales.

Normalización lingüística

- Tokenización.
- Eliminación de *stopwords*.
- Stemming.
- Lemmatization.

El objetivo es reducir ruido, estandarizar las reseñas y generar textos más útiles para los modelos.

Representación vectorial: BoW vs TF-IDF

Bag of Words

- Cuenta frecuencia de palabras.
- Fácil de interpretar.
- Buena línea base.
- No considera importancia global.

TF-IDF

- Pondera palabras por importancia.
- Reduce peso de términos comunes.
- Resalta palabras informativas.
- Obtuvo la mejor configuración.

Modelos de clasificación

Modelo	Uso dentro del proyecto
Naive Bayes	Línea base probabilística, rápida y común en texto.
Logistic Regression	Modelo lineal fuerte para clasificación binaria.
SVM lineal	Modelo de margen, adecuado para vectores dispersos y de alta dimensión.

Diseño experimental

Se probaron 12 combinaciones: 2 métodos de procesamiento $\times$ 2 vectorizaciones $\times$ 3 modelos.

Experimentos realizados

Procesamiento	Vectorización	Modelos
Stemming	BoW	Naive Bayes, Logistic Regression, SVM lineal
Stemming	TF-IDF	Naive Bayes, Logistic Regression, SVM lineal
Lemmatization	BoW	Naive Bayes, Logistic Regression, SVM lineal
Lemmatization	TF-IDF	Naive Bayes, Logistic Regression, SVM lineal

Métricas revisadas

Train Accuracy, Test Accuracy, Precision, Recall, F1-score, tiempo de entrenamiento y matrices de confusión.

Ejecución real del proyecto

```
Dataset cargado: 886404 reseñas
label
Positivo 829256
Negativo 57148
Name: count, dtype: int64

Preprocesamiento: stemming
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=194.5815s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=234.9781s
SVM_Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=210.8646s
Representación: TFIDF
Naive Bayes: Train Acc=0.9482 | Test Acc=0.9479 | F1=0.9729 | Tiempo=177.671s
Logistic Regression: Train Acc=0.9718 | Test Acc=0.9702 | F1=0.9842 | Tiempo=199.8773s
SVM_Lineal: Train Acc=0.9732 | Test Acc=0.9711 | F1=0.9847 | Tiempo=254.298s

Preprocesamiento: lemmatization
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=181.8573s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=212.5594s
SVM_Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=263.5835s
Representación: TFIDF
Naive Bayes: Train Acc=0.9482 | Test Acc=0.9479 | F1=0.9729 | Tiempo=189.2878s
Logistic Regression: Train Acc=0.9718 | Test Acc=0.9702 | F1=0.9842 | Tiempo=206.2924s
SVM_Lineal: Train Acc=0.9732 | Test Acc=0.9711 | F1=0.9847 | Tiempo=139.2664s

Resultados guardados en:
/home/other_user/Downloads/Mini_proyecto/sentiment_analysis_nlp_github/outputs/reports/resultados_comparativos.csv
/home/other_user/Downloads/Mini_proyecto/sentiment_analysis_nlp_github/outputs/classification_reports.txt

Mejor configuración:
configuracion representacion procesamiento modelo train_accuracy test_accuracy precision recall f1_score test_loss tiempo_entrenamiento seg num_documentos
TFIDF + lemmatization tfidf lemmatization SVM_Lineal 0.9732 0.9711 0.9779 0.9915 0.9847 NaN 139.2664 (m)(mye)(myenv)(mye)(myenv) othe(myenv)(myenv) (myenv)(m)(m)(m)(m)(myenv) other_
(myenv) other_user@other:/Downloads/Mini_proyecto/sentiment_analysis_nlp_github$
python -m src.main --data data/raw/kindle_reviews.csv
Dataset cargado: 886404 reseñas
label
Positivo 829256
Negativo 57148
Name: count, dtype: int64

Preprocesamiento: stemming
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=194.5815s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=234.9781s
SVM_Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=210.8646s
Representación: TFIDF
Naive Bayes: Train Acc=0.9482 | Test Acc=0.9479 | F1=0.9729 | Tiempo=177.671s
Logistic Regression: Train Acc=0.9718 | Test Acc=0.9702 | F1=0.9842 | Tiempo=199.8773s
SVM_Lineal: Train Acc=0.9732 | Test Acc=0.9711 | F1=0.9847 | Tiempo=254.298s

Preprocesamiento: lemmatization
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=181.8573s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=212.5594s
SVM_Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=263.5835s
Representación: TFIDF
(myenv) other_user@other:/Downloads/Mini_proyecto/sentiment_analysis_nlp_github$ 0.9711 0.9779 0.9915 0.9847 NaN 139.2664 (m)(mye)(myenv)(mye)(myenv) othe(myenv)(myenv) (myenv)(m)(m)(m)(m)(myenv) other_
```

Captura real de la

terminal durante la ejecución del pipeline.

Cierre de ejecución y mejor configuración

```

(yenv) other_user@other:~/Downloads/Mini_proyecto/sentiment_analysis_nlp_github$ python -m src.main --data data/raw/kindle_reviews.csv
Dataset cargado: B866404 reseñas
label
Positivo      829256
Negativo      57148
Name: count, dtype: int64

Preprocesamiento: stemming
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=194.5015s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=234.9781s
SVM Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=210.8646s
Representación: TFIDF
Naive Bayes: Train Acc=0.9482 | Test Acc=0.9479 | F1=0.9729 | Tiempo=177.671s
Logistic Regression: Train Acc=0.9718 | Test Acc=0.9702 | F1=0.9842 | Tiempo=199.8773s
SVM Lineal: Train Acc=0.9732 | Test Acc=0.9711 | F1=0.9847 | Tiempo=254.298s

Preprocesamiento: lemmatization
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=181.8573s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=212.5594s
SVM Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=203.5835s
Representación: TFIDF
Naive Bayes: Train Acc=0.9482 | Test Acc=0.9479 | F1=0.9729 | Tiempo=189.2878s
Logistic Regression: Train Acc=0.9718 | Test Acc=0.9702 | F1=0.9842 | Tiempo=206.2924s
SVM Lineal: Train Acc=0.9732 | Test Acc=0.9711 | F1=0.9847 | Tiempo=139.2664s

Resultados guardados en:
/home/other_user/Downloads/Mini_proyecto/sentiment_analysis_nlp_github/outputs/reports/resultados_comparativos.csv
/home/other_user/Downloads/Mini_proyecto/sentiment_analysis_nlp_github/outputs/classification_reports.txt

Mejor configuración:
  configuration  representación  procesamiento  modelo  train_accuracy  test_accuracy  precision  recall  f1_score  test_loss  tiempo_entrenamiento  seg  num_documentos
TFIDF + lemmatization  tfidf  lemmatization  SVM Lineal      0.9732      0.9711  0.9779  0.9915  0.9847      NaN      139.2664  (mye(myenv(myemyenv) othe(myenv(myenv) (myenv(m(n(m(n(m(s(myenv) other

(yenv) other_user@other:~/Downloads/Mini_proyecto/sentiment_analysis_nlp_github$
python -m src.main --data data/raw/kindle_reviews.csv
Dataset cargado: B866404 reseñas
label
Positivo      829256
Negativo      57148
Name: count, dtype: int64

Preprocesamiento: stemming
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=194.5015s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=234.9781s
SVM Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=210.8646s
Representación: TFIDF
Naive Bayes: Train Acc=0.9482 | Test Acc=0.9479 | F1=0.9729 | Tiempo=177.671s
Logistic Regression: Train Acc=0.9718 | Test Acc=0.9702 | F1=0.9842 | Tiempo=199.8773s
SVM Lineal: Train Acc=0.9732 | Test Acc=0.9711 | F1=0.9847 | Tiempo=254.298s

Preprocesamiento: lemmatization
Representación: BOW
Naive Bayes: Train Acc=0.9373 | Test Acc=0.9363 | F1=0.9653 | Tiempo=181.8573s
Logistic Regression: Train Acc=0.9723 | Test Acc=0.9698 | F1=0.984 | Tiempo=212.5594s
SVM Lineal: Train Acc=0.9715 | Test Acc=0.9691 | F1=0.9836 | Tiempo=203.5835s

```


La corrida identifica

como mejor configuración a TF-IDF + lemmatization + SVM lineal.

Resultados comparativos

Configuración	Modelo	Train	Test	F1	Tiempo
BoW + stemming	NB	0.9373	0.9363	0.9653	194.50
BoW + stemming	LR	0.9723	0.9698	0.9840	234.98
BoW + stemming	SVM	0.9715	0.9691	0.9836	210.86
TF-IDF + stemming	NB	0.9482	0.9479	0.9729	177.67
TF-IDF + stemming	LR	0.9718	0.9702	0.9842	199.08
TF-IDF + stemming	SVM	0.9732	0.9711	0.9847	254.30
BoW + lemma	NB	0.9373	0.9363	0.9653	181.86
BoW + lemma	LR	0.9723	0.9698	0.9840	212.56
BoW + lemma	SVM	0.9715	0.9691	0.9836	203.58
TF-IDF + lemma	NB	0.9482	0.9479	0.9729	189.29
TF-IDF + lemma	LR	0.9718	0.9702	0.9842	206.29
TF-IDF + lemma	SVM	0.9732	0.9711	0.9847	139.27


Comparación de F1-score



Los

modelos lineales, especialmente SVM lineal y Logistic Regression, obtuvieron los F1-score más altos.

Comparación de tiempos de entrenamiento



configuración también tuvo un tiempo competitivo en la ejecución registrada.

La mejor

Mejor configuración

Representación

TF-IDF

Pondera términos informativos

Modelo

SVM lineal

Adecuado para texto vectorizado

F1-score

0.9847

Mejor métrica final

Procesamiento

Lemmatization

Normaliza palabras

Test Accuracy

0.9711

Exactitud en prueba


Tiempo

139.2664 s


Entrenamiento registrado

Matrices de confusión: Bag of Words

BoW + lemmatization




BoW + stemming




Se muestran las matrices del modelo SVM lineal para comparar el desempeño con Bag of Words bajo ambos métodos de normalización.

Matrices de confusión: TF-IDF

TF-IDF + lemmatization




TF-IDF + stemming




TF-IDF con SVM lineal logra el mejor F1-score. La versión con lemmatization fue la más conveniente por resultado y tiempo.

Matrices de confusión: todos los modelos base


BoW + lemma NB




BoW + lemma LR




BoW + lemma SVM




TF-IDF + lemma NB



TF-IDF + lemma LR



TF-IDF + lemma SVM



Análisis: BoW vs TF-IDF

Bag of Words

Funciona bien como línea base y obtuvo resultados altos. Sin embargo, trata las palabras principalmente como conteos y no distingue si un término es común o realmente informativo.

TF-IDF

Generó la mejor configuración porque reduce el peso de palabras frecuentes y resalta términos más útiles para diferenciar reseñas positivas y negativas.

Análisis: Stemming vs Lemmatization

- Con BoW, stemming y lemmatization produjeron resultados prácticamente iguales.
- Con TF-IDF, ambos métodos alcanzaron el mismo F1-score máximo con SVM lineal.
- En la ejecución final, **TF-IDF + lemmatization + SVM lineal** fue más rápido que TF-IDF + stemming + SVM lineal.

Decisión final

Se selecciona lemmatization porque conserva mejor la forma base de las palabras y fue competitiva en tiempo y desempeño.

Análisis: comparación de modelos

Naive Bayes

Rápido y útil como línea base, pero con menor F1-score.

Logistic Regression

Desempeño alto y estable en casi todas las configuraciones.

SVM lineal

Mejor F1-score. Funciona muy bien con vectores dispersos.

Modelo final recomendado: SVM lineal

Reto principal: desbalance de clases



Implicación

Accuracy no es suficiente, porque un modelo podría verse bien al favorecer la clase mayoritaria.

Solución en evaluación

Se revisa F1-score porque combina precision y recall, dando una evaluación más equilibrada.

Uso de IA en el proyecto

- Apoyo para organizar la estructura inicial del repositorio.
- Sugerencia de funciones auxiliares de carga, limpieza y evaluación.
- Apoyo en redacción de documentación y revisión de la rúbrica.
- El equipo ejecutó el proyecto, validó resultados y corrigió errores.

Porcentaje estimado

El código asistido por IA se mantiene por debajo del 30 %.

Errores encontrados y correcciones

Reto encontrado	Corrección aplicada
El dataset real tarda mucho por su tamaño. El dataset está desbalanceado. La clase neutral genera ambigüedad. Algunos modelos no tienen predict_proba.	Se limitó el vocabulario con <code>MAX_FEATURES = 5000</code> . Se priorizó F1-score sobre accuracy. Se eliminaron reseñas con calificación 3. <code>test_loss</code> queda vacío cuando no aplica.

Conclusiones

- Se implementó un pipeline completo de *Sentiment Analysis* con NLP.
- El sistema transforma texto en vectores y entrena modelos supervisados.
- La mejor configuración fue **TF-IDF + lemmatization + SVM lineal**.
- El mejor Test Accuracy fue **0.9711**.
- El mejor F1-score fue **0.9847**.
- El principal reto fue el desbalance de clases.

Participación del equipo

Integrante	Parte sugerida para exponer
Pablo García Espejo	Introducción, objetivo y planteamiento del problema.
Diego Arath Franco Herrera	Dataset, preparación de etiquetas y desbalance de clases.
Miguel Ángel Guerrero Alvarez	Preprocesamiento NLP: limpieza, tokenización, stopwords y normalización.
Manuel de la Torre	Vectorización, modelos y diseño experimental.
Giulian Thibaut Elías-Libera	Resultados, matrices de confusión, uso de IA y conclusiones.

- Bird, S., Klein, E., & Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly Media.
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Srivastava, B. (s. f.). *Amazon Reviews: Kindle Store Category*. Kaggle.
<https://www.kaggle.com/datasets/bharadwaj6/kindle-reviews>

Gracias